

BÀI ÔN TẬP: PHÂN TÍCH DỮ LIỆU & HỌC SÂU

Chủ đề: Tiền xử lý dữ liệu và Xây dựng mô hình Cơ bản

Môi trường thực hành: Jupyter Notebook / Google Colab

PHẦN 1: TIỀN XỬ LÝ VÀ TRỰC QUAN HÓA DỮ LIỆU (6.0 Điểm)

Câu 1: Nạp và Khám phá dữ liệu (1.0 điểm)

Sử dụng thư viện seaborn, hãy tải bộ dữ liệu tích hợp sẵn có tên là **'titanic'** (tập dữ liệu về hành khách trên tàu Titanic).

- In ra 5 dòng đầu tiên của tập dữ liệu.
- In ra thông tin tổng quan của dữ liệu (sử dụng hàm `info()` để xem kiểu dữ liệu và số lượng giá trị Non-Null của từng cột).

Câu 2: Xử lý giá trị khuyết (1.5 điểm)

Tập dữ liệu 'titanic' có một số cột chứa giá trị khuyết (Missing Values).

- Đếm số lượng giá trị khuyết ở mỗi cột.
- Cột 'deck' có quá nhiều giá trị khuyết. Hãy viết lệnh xóa hoàn toàn cột này khỏi DataFrame.
- Cột 'age' (tuổi) có một số giá trị khuyết. Hãy điền các giá trị khuyết này bằng **Trung bình (Mean)** tuổi của tất cả hành khách.

Câu 3: Phân tích và Trực quan hóa (2.0 điểm)

Sử dụng matplotlib và seaborn để thực hiện các yêu cầu sau:

- Vẽ biểu đồ cột (Bar plot hoặc Count plot) thể hiện số lượng hành khách sống sót (cột 'survived') phân chia theo giới tính (cột 'sex').
- Vẽ biểu đồ phân bố (Histogram hoặc KDE) thể hiện phân bố độ tuổi ('age') của các hành khách trên tàu.
- Tính toán ma trận tương quan giữa các biến số (chỉ lấy các cột có kiểu dữ liệu dạng số như 'survived', 'pclass', 'age', 'fare') và vẽ **Heatmap** biểu diễn ma trận đó.

Câu 4: Mã hóa dữ liệu (1.5 điểm)

Để chuẩn bị dữ liệu cho mô hình học máy:

- Sử dụng kỹ thuật **Label Encoding** (hoặc map dictionary) để chuyển đổi cột 'sex' ('male', 'female') thành dạng số (0, 1).
- Sử dụng kỹ thuật **One-Hot Encoding** (pd.get_dummies) cho cột 'embarked' (Cảng lên tàu) và gộp vào DataFrame chính.

PHẦN 2: XÂY DỰNG MÔ HÌNH HỌC SÂU CƠ BẢN (4.0 Điểm)

Câu 5: Chuẩn bị dữ liệu cho Học sâu (1.5 điểm)

Chúng ta sẽ dự đoán khả năng sống sót ('survived') dựa trên 3 đặc trưng: 'pclass' (Hạng vé), 'sex' (Giới tính đã mã hóa), và 'age' (Tuổi đã điền khuyết).

- Tạo biến X chứa 3 cột đặc trưng trên, và biến y chứa cột 'survived'.
- Sử dụng `train_test_split` từ thư viện `sklearn` để chia dữ liệu thành tập huấn luyện (train) và tập kiểm thử (test) với tỷ lệ 80% - 20%.
- (Tùy chọn nhưng khuyến khích): Chuẩn hóa (Scale) tập `X_train` và `X_test` bằng `StandardScaler`.

Câu 6: Xây dựng mạng Nơ-ron nhân tạo (ANN) (2.5 điểm)

Sử dụng thư viện `TensorFlow` / `Keras` để xây dựng mô hình phân loại nhị phân (sống hoặc chết).

- Khởi tạo một mô hình `Sequential()`.
- Thêm một lớp ẩn (Dense layer) với 16 nơ-ron và hàm kích hoạt 'relu'. Nhớ cấu hình `input_shape` phù hợp với số lượng đặc trưng đầu vào (3 đặc trưng).
- Thêm lớp đầu ra (Output layer) với 1 nơ-ron và hàm kích hoạt 'sigmoid' (vì đây là bài toán phân loại nhị phân).
- Compile mô hình với optimizer là 'adam', loss function là 'binary_crossentropy', và metrics là ['accuracy'].
- Huấn luyện mô hình (fit) với tập train trong 20 epochs. In ra kết quả đánh giá (evaluate) trên tập test.

--- HẾT ---

Sinh viên lưu code và kết quả chạy thành file .ipynb để nộp bài.